



Université Virtuelle de Côte d'Ivoire



Union – Discipline - Travail



Ministère de l'Enseignement
Supérieur et de la
Recherche Scientifique

Niveau : master I

Spécialité : Big Data Analytics

Année universitaire : 2024-2025

CLASSIFICATION DE LA LITHIASE BILIAIRE A PARTIR DE DONNEES CLINIQUES NON IMAGEES

Membres du groupe ayant réalisé le projet :

COULIBALY Nahoua Daouda

KONATE Aboudoulaye

SOGODOGO Fangniere

SINON Bakary

KESSE Epiphanie

TOURE Djakaria

TOUALY Djolohonon Deborah

KANGAH Kouadio Franck Huberson

YAO Kouadio David Bienvenu

KOUASSI Kouame Yannick

Enseignant :

Dr. AYIKPA Kacoutchy Jean

TABLES DES MATIERES

I.	INTRODUCTION	3
II.	ANALYSE DU DATASET.....	4
II.1	Présentation du dataset.....	4
II.2	Statistiques globales	4
III.	SELECTION DES VARIABLES PERTINENTES.....	8
III.1	Méthode de sélection des variables	8
III.2	Les variables sélectionnées.....	8
IV.	MODELE DE CLASSIFICATION ET MIS EN OEUVRE.....	9
IV.1	Affichage des scores.....	9
IV.2	Matrice de confusion	9
IV.3	COURBE ROC	10
V.	RESULTATS ET ANALYSES.....	10
V.1	ANALYSE DES PERFORMANCES GLOBALES	10
V.2	ANALYSE DE LA MATRICE DE CONFUSION MOYENNE	11
V.3	EVOLUTION SYNTHETIQUE	11
VI.	CONCLUSION ET LIMITES.....	13

I. INTRODUCTION

La lithiase biliaire, communément appelée calculs biliaires, constitue une pathologie fréquente affectant les voies biliaires, avec des répercussions notables sur la santé publique. Son diagnostic repose traditionnellement sur des examens d'imagerie médicale, tels que l'échographie ou la tomodensitométrie. Toutefois, ces méthodes peuvent s'avérer coûteuses, inaccessibles dans certains contextes, ou parfois peu sensibles aux stades précoces de la maladie.

Dans ce contexte, l'émergence de l'intelligence artificielle, et plus précisément des algorithmes d'apprentissage automatique, offre une alternative prometteuse pour la détection précoce et non invasive de cette pathologie. Le présent travail vise à concevoir un modèle de classification supervisée capable de prédire la présence ou l'absence de lithiase biliaire à partir de données cliniques non imagées. Ces données, issues d'un jeu de données réel collecté en milieu hospitalier, intègrent des variables démographiques, biologiques et issues de la bio-impédancemétrie.

L'objectif est ainsi double : démontrer la faisabilité de la prédiction de la lithiase biliaire à partir d'informations cliniques simples, et évaluer les performances d'un couple méthode de sélection-algorithme imposé, en le comparant à d'autres modèles de classification.

II. ANALYSE DU DATASET

II.1 Présentation du dataset

a. Informations générales

Nombre d'individus : 319

Variables : 39 (démographiques, bio impédance, laboratoire)

Variable cible : Gallstone Status (0 = absence, 1 = présence)

Équilibrage du dataset :

- Absence : 161 (50,5%)
- Présence : 158 (49,5%)

II.2 Statistiques globales

a. Mesures de tendances centrales et de dispersions

Gallstone Status Age Gender Comorbidity \					High Density Lipoprotein (HDL) Triglyceride \		
count	319.000000	319.000000	319.000000	319.000000	count	319.000000	319.000000
mean	0.495298	48.068966	0.492163	0.335423	mean	49.475549	144.502163
std	0.500763	12.114558	0.500724	0.517340	std	17.718701	97.904493
min	0.000000	20.000000	0.000000	0.000000	min	25.000000	1.390000
25%	0.000000	38.500000	0.000000	0.000000	25%	40.000000	83.000000
50%	0.000000	49.000000	0.000000	0.000000	50%	46.500000	119.000000
75%	1.000000	56.000000	1.000000	1.000000	75%	56.000000	172.000000
max	1.000000	96.000000	1.000000	3.000000	max	273.000000	838.000000
Coronary Artery Disease (CAD) Hypothyroidism Hyperlipidemia \					Aspartat Aminotransferaz (AST) Alanin Aminotransferaz (ALT) \		
count	319.000000		319.000000		count	319.000000	319.000000
mean	0.037618		0.028213		mean	21.684953	26.855799
std	0.190568		0.165841		std	16.697605	27.884413
min	0.000000		0.000000		min	8.000000	3.000000
25%	0.000000		0.000000		25%	15.000000	14.250000
50%	0.000000		0.000000		50%	18.000000	19.000000
75%	0.000000		0.000000		75%	23.000000	30.000000
max	1.000000		1.000000		max	195.000000	372.000000
Diabetes Mellitus (DM) Height Weight ... \					Alkaline Phosphatase (ALP) Creatinine \		
count	319.000000	319.00000	319.000000	...	count	319.000000	319.000000
mean	0.134796	167.15674	80.564890	...	mean	73.112539	0.800611
std	0.342042	10.05303	15.709069	...	std	24.181069	0.176433
min	0.000000	145.00000	42.900000	...	min	7.000000	0.460000
25%	0.000000	159.50000	69.600000	...	25%	58.000000	0.650000
50%	0.000000	168.00000	78.800000	...	50%	71.000000	0.790000
75%	0.000000	175.00000	91.250000	...	75%	86.000000	0.920000
max	1.000000	191.00000	143.500000	...	max	197.000000	1.460000

```

      Glomerular Filtration Rate (GFR)  C-Reactive Protein (CRP)  \
count      319.000000      319.000000
mean      100.818903      1.853856
std       16.971396      4.989591
min       10.600000      0.000000
25%       94.170000      0.000000
50%      104.000000      0.215000
75%      110.745000      1.615000
max      132.000000      43.400000


      Hemoglobin (HGB)  Vitamin D
count      319.000000  319.000000
mean      14.418182   21.401411
std       1.775815    9.981659
min       8.500000    3.500000
25%      13.300000   13.250000
50%      14.400000   22.000000
75%      15.700000   28.060000
max      18.800000   53.100000

[8 rows x 39 columns]
Gender
0      162
1      157
Name: count, dtype: int64

```


b. Visualisation

- Distribution de l'âge




Répartition homogène, avec une majorité entre 35 et 60 ans.

- IMC



Distribution normale centrée autour de 28


- BMI



Le BMI est en moyenne plus élevé chez les patients ayant des calculs


- Répartition de la variable cible : Gallstone

Répartition des cas de calculs biliaires



Une répartition presque équilibrée 50,50% de présence et 49,5% d'absence

- Matrice de corrélation(pearson)



Les variables les plus corrélées à la cible (présence de calculs) sont :

C-Reactive Protein (CRP)
Total body fat ratio (TBFR)
Total fat content (TFC)
Hyperlipidemia
HDL
Gender
Visceral Fat Area (VFA)
BMI
Vitamin D (corrélation négative)

III. SELECTION DES VARIABLES PERTINENTES

III.1 Méthode de sélection des variables

La sélection automatique par score ANOVA (SelectKBest(f_classif)) a été utilisée pour réduire la dimensionnalité du jeu de données et retenir les variables les plus discriminantes (testé pour $K = 8$).

Réduit le surapprentissage

Met en avant les variables vraiment informatives pour la prédiction

NB : méthode imposée pour le groupe E

III.2 Les variables sélectionnées

N°	Variables
1	Extracellular Water (ECW)
2	Total Body Fat Ratio (TBFR) (%)
3	Lean Mass (LM) (%)
4	Bone Mass (BM)
5	Total Fat Content (TFC)
6	C-Reactive Protein (CRP)
7	Hemoglobin (HGB)
8	Vitamin D


IV. MODELE DE CLASSIFICTAION ET MIS EN OEUVRE

Validation croisée stratifiée (5 folds) avec normalisation des variables.

IV.1 Affichage des scores


Scores	Valeurs
Accuracy	0.759
F1	0.744
recall	0.716
Roc_auc	0.827
mcc	0.521

IV.2 Matrice de confusion



MSE moyen : 0.241

IV.3 COURBE ROC



V. RESULTATS ET ANALYSES

Interprétation des résultats Random Forest (K=8, sélection “f_classif”)

V.1 ANALYSE DES PERFORMANCES GLOBALES

Exactitude globale (accuracy) : 0.759 ± 0.034

Le modèle classe correctement ~76 % des patients, avec une bonne régularité entre les plis de validation croisée.

F1-score : 0.744 ± 0.044

L'équilibre entre précision et rappel est bon. Cet indicateur montre que le modèle pénalise peu l'un ou l'autre (peu de classes déséquilibrées ou sur-appries).

Recall (rappel/sensibilité) : 0.716 ± 0.073

Le modèle détecte correctement $\sim 72\%$ des patients réellement porteurs de calculs biliaires, un taux satisfaisant pour une application clinique exploratoire.

MCC : 0.521 ± 0.064

Le coefficient de Matthews, robuste aux différences de taille de classes, confirme la performance honorable du modèle sur l'ensemble du jeu.

ROC-AUC : 0.827 ± 0.035

La courbe ROC indique une très bonne capacité de discrimination globale : le modèle différencie clairement les patients avec et sans calculs.

MSE (erreur quadratique moyenne) : 0.241 ± 0.034

Ce score bas confirme la concordance globale entre prédictions et réalité.

V.2 ANALYSE DE LA MATRICE DE CONFUSION MOYENNE

Sur 65 patients de moyenne par fold :

26 vrais négatifs (absence bien détectée)

23 vrais positifs (présence bien détectée)

6 faux positifs (patients sains classés malades)

9 faux négatifs (malades classés sains)

Lecture clinique :

Le modèle se trompe un peu plus souvent en loupant un cas avec calculs (9 FNs > 6 FPs), mais l'écart est modéré : le rappel reste largement supérieur à 0.7.

La majorité des patients est bien classée (~ 3 sur 4).

Les erreurs ne sont pas massivement biaisées vers un type, ce qui montre que le modèle n'est ni trop « pessimiste » ni trop « optimiste ».

V.3 EVOLUTION SYNTHETIQUE

Robustesse & cohérence :

Écart-type faible pour toutes les métriques → le modèle est stable sur tous les splits de la cross-validation.

Puissance discriminative :

Un AUC à 0.83 et un MCC nettement positifs attestent d'un modèle de qualité, adapté à la détection « non imagée » de la maladie.

Limites à noter :

9/65 malades non détectés par fold, et quelques faux positifs → invite à l'amélioration (tuning hyperparamètres, méthodes complémentaires, nouvelle sélection de features...).

VI. CONCLUSION ET LIMITES

Le travail réalisé a permis de concevoir et d'évaluer un pipeline de classification supervisée, adapté à la prédiction de la présence de calculs biliaires à partir de variables cliniques non issues de l'imagerie. L'approche, centrée sur une sélection de variables par SelectKBest utilisant le score $f_classif$, associée à un classifieur Random Forest, répond strictement au cahier des charges fourni. L'efficacité de cette configuration se traduit par des scores solides : un taux d'exactitude de 75,9%, un F1-score de 0,744, une aire sous la courbe ROC de 0,827 et un coefficient de corrélation de Matthews de 0,521 après validation croisée. Le choix des variables les plus discriminantes s'avère cohérent sur le plan médical, La sélection met en avant des marqueurs tels que la répartition de l'eau corporelle, la masse maigre, la graisse totale, la protéine C-réactive, l'hémoglobine et la vitamine D. Comparativement à la régression logistique et au SVM à noyau RBF, les performances obtenues avec cette méthodologie apparaissent comparables voire légèrement supérieures, confortant la pertinence de la sélection et du modèle retenus sur cet ensemble de données équilibré et bien structuré.

Malgré la robustesse des résultats, diverses limites subsistent. La performance, bien que satisfaisante, laisse apparaître une marge d'erreur qui limite une application immédiate en contexte clinique, en particulier avec un MCC d'environ 0,52. Le caractère monocentrique des données, issues d'un unique hôpital et d'une période restreinte, peut générer un biais de population ou de pratiques, ce qui interroge la généralisabilité des conclusions. L'absence d'indicateurs issus de l'imagerie, imposée par le cahier des charges, restreint la capacité à résoudre certains cas limites qui bénéficieraient d'informations échographiques complémentaires. Concernant les algorithmes, seuls Random Forest, SVM et régression logistique ont été testés ; d'autres méthodes, telles que le Gradient Boosting, XGBoost ou des modèles bayésiens, restent à explorer pour d'éventuels gains en performance. L'optimisation des hyperparamètres n'a pas fait l'objet d'une recherche approfondie, ce qui pourrait toutefois renforcer la robustesse du modèle. Par ailleurs, le rapport ne comporte pas d'analyse détaillée de l'importance ou de l'influence des variables retenues, ce qui limite la transparence et l'explicabilité des décisions. Enfin, l'utilisation du score $f_classif$ pour la sélection ne permet pas de détecter les interactions ni les relations non linéaires entre variables, ce qui peut entraver le potentiel discriminant du modèle sur des données cliniques complexes.

En somme, ce travail propose un pipeline fiable et cohérent pour la prédiction non imagée de la lithiase biliaire, pose des bases solides pour des applications futures et laisse entrevoir plusieurs pistes d'amélioration pour consolider la pertinence et l'applicabilité des modèles développés.